



UNIVERSITÀ  
DEGLI STUDI DI BARI  
ALDO MORO

DIPARTIMENTO DI INFORMATICA

CORSO DI LAUREA IN INFORMATICA

---

TESI DI LAUREA  
IN

## Analisi dei Pattern delle Chiamate Api per la Classificazione Malware

**RELATORI:**

Prof.ssa Annalisa Appice  
Dr. Giuseppina Andresini

**LAUREANDO:**

Giacomo Gaudio

---

ANNO ACCADEMICO 2024 2025



# Indice

<b>Sommario</b>	3
<b>1 Introduzione</b>	4
1.1 Formato Windows PE malware . . . . .	5
1.2 Categorie Malware . . . . .	6
1.3 Chiamata Api Windows . . . . .	7
1.4 Contributi . . . . .	8
<b>2 Background e Stato dell'Arte</b>	9
2.1 Analisi Statica e Dinamica . . . . .	9
2.2 Machine Learning . . . . .	11
2.3 Classificazione . . . . .	12
2.3.1 Algoritmi di Classificazione . . . . .	13
2.4 Approcci di Machine Learning per Windows PE Malware Detection . . .	15
<b>3 Approccio Proposto</b>	19
3.1 Descrizione . . . . .	19
3.1.1 Raccolta e Standardizzazione dei Dati . . . . .	19
3.1.2 Ingegneria delle Caratteristiche: Il Modello Bag-of-Words . . . . .	20
3.1.3 Addestramento e Valutazione . . . . .	21
3.2 OOP & UML . . . . .	21
3.2.1 Convenzioni e Notazione UML . . . . .	24
<b>4 Validazione Empirica</b>	29
4.1 Dataset . . . . .	29
4.2 Metriche di Valutazione . . . . .	29
4.3 Risultati . . . . .	31
<b>5 Conclusioni e Sviluppi Futuri</b>	33
<b>6 Appendice</b>	35
6.1 Ambiente di Sviluppo . . . . .	35



# Disclaimer

Tutti i marchi, nomi commerciali, prodotti e loghi menzionati in questa tesi sono di proprietà dei rispettivi titolari. L'autore non rivendica alcun diritto di proprietà su tali marchi o nomi commerciali e li utilizza solo a scopo informativo e descrittivo, senza alcun intento di violazione.



# Sommario

Andrà inserito il riassunto di tutta la tesi.

# Capitolo 1

## Introduzione

Con l'avvento dell'era digitale, attività e servizi, in ambito e-commerce, pubblica amministrazione, servizi finanziari e sanitari, vengono sempre di più digitalizzati in Italia. Secondo i dati ISTAT, l'86,2% delle famiglie italiane dispone di un accesso ad internet a testimonianza di un uso sempre più popolare [1]. Tuttavia, l'aumento della connettività comporta inevitabilmente anche una maggiore esposizione alle minacce informatiche. Nel 2024, l'Italia ha registrato il 10% degli attacchi informatici globali; secondo il rapporto Clusit, circa un terzo di tali attacchi è stato veicolato tramite l'utilizzo di malware [2]. Per malware si intende un'istanza di un programma il cui intento sia malevole come carpire informazioni personali e/o arrecare danni ai dispositivi [3]. Per poter identificare i malware esistono due tipi di analisi: statica e dinamica. L'analisi statica prevede l'analisi del codice binario, analizzando ogni ramo di esecuzione possibile alla ricerca di codice malevolo. L'analisi dinamica invece prevede l'esecuzione del programma all'interno di una sandbox, ovvero un ambiente isolato e controllato che impedisce al software di arrecare danni reali al sistema. In questo ambiente è possibile osservare i suoi comportamenti alla ricerca di quelli simili ai malware [4]. Con riferimento alle informazioni veicolate dalle API (Application Programming Interface), per comportamenti intendiamo l'insieme (ordinato) delle chiamate API al Kernel per permettere l'esecuzione dell'applicativo; un API è un modo per interagire con un sistema senza l'ausilio di una interfaccia grafica [5]. Un singolo "comportamento" è effettivamente la singola chiamata API prendendo il nome di "API Call"; mentre la lista (ordinata) prende il nome "API call sequence" [6]. L'obiettivo di questa tesi è classificare un programma in base ai suoi comportamenti. Per raggiungere tale scopo è stato formalizzato e valutato un approccio che apprende un classificatore, utilizzando sequenze di chiamate API come input e algoritmi di machine learning per distinguere le varie categorie.



## 1.1 Formato Windows PE malware

Per poter essere eseguito in *Microsoft Windows*, un programma deve presentare una logica applicativa interpretabile dal sistema operativo. A tale scopo, il sistema operativo Windows utilizza il formato **PE** (Portable Executable), così denominato in quanto progettato per non essere vincolato a una specifica architettura [7]. Un file in formato **PE** ha nel seguente ordine le seguenti intestazioni:

1. **Stub MS-DOS**: area iniziale del file PE, compatibile con il sottosistema **MS-DOS**. In assenza di istruzioni specifiche da parte dello sviluppatore, contiene un programma di default che visualizza il messaggio: “Impossibile eseguire questo programma in modalità DOS”.
2. **Firma PE**: campo che identifica il file come appartenente al formato **Portable Executable (PE)** e ne consente il corretto riconoscimento da parte del loader di Windows.
3. **Intestazione COFF**: fornisce informazioni fondamentali sul file, come il tipo di macchina su cui è destinato a essere eseguito, il numero di sezioni e la data di compilazione.
4. **Intestazione facoltativa (solo immagine)**: sezione che specifica le informazioni necessarie al caricamento ed esecuzione del programma. È composta da tre sottosezioni principali:
  - **Campi standard intestazione facoltativi** : includono l’indirizzo di entry point del programma, la dimensione del codice e dei dati, e altri parametri di base.
  - **Campi specifici dell’intestazione facoltativa di Windows**: contengono informazioni più dettagliate, come la versione minima del sistema operativo richiesto, le dimensioni massime di heap e stack, e i valori di allineamento della memoria.
  - **Directory dati intestazione facoltative**: riferimenti alle tabelle e alla loro dimensione delle risorse esterne come le ddl.

Una ddl è una libreria che contiene codice e dati utilizzabili da più di un programma contemporaneamente. Ogni programma può utilizzare le ddl del sistema operativo Windows per ottenere memoria, accesso a risorse, far apparire elementi a schermo ed accedere alla rete [8]. I malware utilizzano queste librerie per poter eseguire comportamenti malevoli.

## 1.2 Categorie Malware

La definizione di *malware* è generica e include tutte le tipologie di software malevolo; per agevolare le attività di rilevamento e classificazione, è utile suddividerli in categorie più specifiche sulla base delle loro finalità e modalità di azione. Nel contesto di questo lavoro di tesi, sono state individuate e considerate le seguenti specializzazioni di software:

- **Unknown:** applicazioni per le quali non è stato possibile determinare con certezza se sono benevoli o meno.
- **Goodware:** software legittimo, privo di finalità malevoli.
- **Malware:** denominazione generica per software malevolo, utilizzata nei casi in cui non sia possibile definire una categoria più specifica.
- **Backdoor:** programma che crea un accesso nascosto al sistema compromesso, permettendo all'attaccante di controllarlo da remoto [9].
- **Trojan:** software che si maschera da applicazione legittima ma che, una volta eseguito, consente operazioni malevole come la modifica o la cancellazione dei dati [10].
- **Virus:** programma in grado di infettare altri file e diffondersi all'interno di un sistema, con lo scopo di danneggiare il corretto funzionamento dell'host [10].
- **Worm:** simili ai virus, ma in grado di diffondersi autonomamente attraverso la rete, senza richiedere l'intervento dell'utente [10].
- **Dropper:** componente malevolo progettato per scaricare o installare altri malware sul sistema target [11].
- **Spyware:** software che raccoglie informazioni sensibili dall'utente o dal sistema infetto e le trasmette a un'entità esterna [10].
- **Adware:** programma che raccoglie informazioni sulle abitudini dell'utente al fine di proporre pubblicità mirata; in alcuni casi può deviare la navigazione verso siti malevoli [10].
- **Packed:** malware compresso (almeno una volta) tramite tecniche di *packing* per eludere i controlli degli antivirus [12].

## 1.3 Chiamata Api Windows

Le chiamate API (Application Programming Interface) di sistema consentono agli sviluppatori di accedere alle risorse della macchina necessarie per l'esecuzione di un applicativo. Attraverso tali interfacce è possibile interagire con componenti fondamentali come la rete, la memoria, i dispositivi di input/output e l'interfaccia grafica. Le API risultano fortemente dipendenti dal sistema operativo su cui vengono eseguite. In ambiente Windows, le API garantiscono che un'applicazione possa funzionare correttamente su diverse versioni del sistema operativo, sfruttando al tempo stesso le specifiche funzionalità introdotte nelle specifiche versioni [13]. Le API di Windows coprono un ampio spettro di funzionalità, tra cui: interfaccia utente e shell, gestione dell'input e della messaggistica, accesso ai dati e archiviazione, diagnostica, grafica e multimedialità, dispositivi, servizi di sistema, sicurezza e identità, installazione e manutenzione di applicazioni, amministrazione e gestione del sistema, rete e connettività Internet.

Un esempio rappresentato dal malware di tipo **Spyware**, che può invocare ripetutamente la funzione `GetKeyboardState` [14] per recuperare lo stato degli ultimi 256 tasti premuti dall'utente, potenzialmente contenenti credenziali sensibili. Nella documentazione ufficiale, i requisiti della funzione sono riassunti in Tabella 1.1.

Tabella 1.1: Requisiti

Voce	Valore
Client minimo supportato	Windows 2000 Professional (solo app desktop)
Server minimo supportato	Windows 2000 Server (solo app desktop)
Piattaforma di destinazione	Windows
Intestazione	<code>winuser.h</code> (include <code>Windows.h</code> )
Libreria	<code>User32.lib</code>
DLL	<code>User32.dll</code>
Set di API	<code>ext-ms-win-ntuser-rawinput-l1-1-0</code> (Windows 10, versione 10.0.14)

Come si nota, alla voce **ddl** è indicata la libreria `User32.dll`. Questa verrà referenziata nella sezione *Directory dati dell'intestazione facoltativa* dell'eseguibile corrispondente, permettendo al sistema operativo di risolvere la chiamata in fase di esecuzione.

Nel contesto di questo lavoro di tesi, non siamo interessati alla presenza di una singola chiamata API in sé, quanto piuttosto alla frequenza con cui tali chiamate compaiono all'interno delle sequenze. È infatti la distribuzione delle invocazioni a costituire la base per la classificazione del comportamento del software.

## 1.4 Contributi

La presente tesi è articolata in quattro capitoli principali: *Introduzione*, *Stato dell'Arte*, *Approccio Proposto*, *Validazione Empirica* e *Appendice*.

Nel capitolo di *Introduzione* vengono presentati il contesto di riferimento, le motivazioni, l'obiettivo del lavoro e il contributo originale fornito.

Il capitolo dedicato allo *Stato dell'Arte* offre un inquadramento teorico e metodologico, approfondendo i principali approcci di analisi del software (statica e dinamica), i fondamenti di *machine learning* con particolare attenzione al compito di classificazione, gli algoritmi utilizzati (Random Forest [15] e XGBoost [16]) e le metriche di valutazione. La sezione si conclude con una panoramica dei lavori correlati nel campo della rilevazione di malware in ambiente Windows.

Nel capitolo *Approccio Proposto* viene descritta in dettaglio la soluzione implementata. Si illustra la modellazione mediante diagrammi UML, l'architettura software sviluppata in Python secondo i principi della programmazione a oggetti.

Successivamente, nel capitolo *Validazione Empirica* verranno presentati i dataset adottati, la standardizzazione adottata, le metriche scelte per la valutazione, i risultati sperimentali ottenuti.

Nel penultimo capitolo, *Conclusioni e Sviluppi Futuri*, verranno tratte le conclusioni del lavoro svolto e saranno delineati alcuni possibili ampliamenti e direzioni di ricerca futura.

Infine, l'*Appendice* contiene note tecniche relative all'ambiente di sviluppo e ulteriori dettagli implementativi, utili a comprendere lo sviluppo effettivo.

# Capitolo 2

## Background e Stato dell'Arte

In questo capitolo vengono presentati i fondamenti concettuali per il riconoscimento dei malware sulla base dei loro comportamenti. Saranno introdotte le due principali tecniche di analisi, statica e dinamica, mettendone in evidenza punti di forza e limitazioni. In seguito, l'attenzione verrà posta sull'analisi dinamica, approccio adottato in questa tesi, illustrandone i principi di machine learning adoperati per la sua realizzazione.

### 2.1 Analisi Statica e Dinamica

L'analisi statica si concentra sull'esame del codice del programma alla ricerca di specifiche sequenze di istruzioni, denominate *virus signature* (firma del virus) [17]. L'efficacia dei sistemi basati su questa tecnica dipende dalla dimensione e dall'aggiornamento del database delle firme e dall'impossibilità, per il software, di modificare nel tempo la propria struttura. Per aggirare tali sistemi di rilevamento, i creatori di malware hanno sviluppato diverse tecniche di offuscamento, che consentono di generare firme differenti rispetto a quelle originarie, rendendo più complessa la loro individuazione. Tra le principali tecniche ritroviamo:

- **Dead Code Insertion** (inserimento di codice morto): aggiunta di istruzioni prive di funzionalità ai fini malevoli, il cui unico scopo è alterare la firma rilevata [17].
- **Code Transposition** (trasposizione del codice): riordinamento delle istruzioni, in modo che la rappresentazione binaria risulti differente pur mantenendo inalterata la logica di esecuzione [17].
- **Register Reassignment** (riassegnazione dei registri): modifica dei registri utilizzati nelle operazioni interne al programma [17].
- **Instruction Substitution** (sostituzione delle istruzioni): rimpiazzo di blocchi di codice con altri semanticamente equivalenti [17].

Il continuo sviluppo di tecniche di offuscamento e l'aggiornamento dei database di firme ha dato vita a un vero e proprio ciclo vizioso, in cui l'evoluzione dei malware procede di pari passo con quella dei sistemi di rilevamento. Ne consegue che l'analisi statica tende a concentrare gli sforzi non tanto sull'identificazione diretta del codice malevolo, quanto piuttosto sulla gestione delle tecniche di offuscamento, finendo così per allontanarsi dal compito primario di rilevare il malware e, soprattutto, di coglierne i reali comportamenti.

L'analisi dinamica supera i limiti dell'approccio statico, poiché osserva i comportamenti effettivi del software durante l'esecuzione. In questo modo non solo riduce l'impatto delle tecniche di offuscamento sul codice, ma consente anche di evidenziare quei casi limite che l'analisi statica difficilmente riesce a cogliere, risultando complessivamente più efficace [18]. Per poter eseguire un'analisi dinamica, esistono diverse tecniche:

- **Hooking** (Aggancio): intercetta chiamate API per monitorare o modificare il comportamento di un programma. Utilizzato spesso dagli antivirus per controllare processi sospetti. Limite: i malware possono rilevare la presenza di hook tramite checksum o controlli interni [18]. Un software per intercettare le chiamate API di Windows è *Detours* [19].
- **Dynamic Binary Instrumentation** (Strumentazione Dinamica del Binario): analizza e modifica il codice binario mentre il programma è in esecuzione, permettendo di osservare ogni istruzione o comportamento in tempo reale. Più difficile da rilevare rispetto all'hooking [18]. Un software che permette tale realizzazione è *Dynamorio* [20].
- **Virtualization** (Virtualizzazione): esegue un sistema operativo guest su hardware reale (host) isolato, sfruttando meccanismi di separazione. Veloce e relativamente sicuro, ma alcuni malware possono rilevare VM tramite differenze hardware/software [18].
- **Application Level Emulation** (Emulazione a Livello di Applicazione): crea un ambiente finto che emula il sistema operativo e l'architettura di istruzioni per singole applicazioni. Utile per analisi real-time e unpacking<sup>1</sup>, ma limitato nella fedeltà: i malware possono rilevare l'emulazione usando istruzioni o API rare [18].
- **Whole System Emulation** (Emulazione dell'Intero Sistema): emula completamente l'hardware di un PC, permettendo l'installazione di un intero sistema operativo guest. Molto utile per osservare comportamenti complessi, unpacking e analisi dettagliata, ma più lento rispetto alla virtualizzazione [18].

---

<sup>1</sup>Per *unpacking* si intende il processo di estrazione del codice originario

Un esempio concreto di implementazione della tecnica di **hooking** è presentato nell'articolo di *Wtrace* [21], dove l'utilizzo della libreria *Detours* permette di intercettare le chiamate API di un processo in esecuzione. Il risultato di tale analisi può essere osservato nella Figura 2.1, che mostra un output delle API Call registrate di un programma in esecuzione:

```

20231125093356718 10468 50.60: trcapi32: 001 -GetCurrentThreadId() -> 29e8
20231125093356718 10468 50.60: trcapi32: 001 +IsWindow(2607f0)
20231125093356718 10468 50.60: trcapi32: 001 -IsWindow() -> 1
20231125093356718 10468 50.60: trcapi32: 001 +GetCurrentThreadId()
20231125093356718 10468 50.60: trcapi32: 001 -GetCurrentThreadId() -> 29e8
20231125093356719 10468 50.60: trcapi32: 001 +GetWindowLongW(2607f0,fffffffe)
20231125093356719 10468 50.60: trcapi32: 001 -GetWindowLongW(,) -> ffffffff
20231125093356719 10468 50.60: trcapi32: 001 +GetWindowLongW(2607f0,0)
20231125093356719 10468 50.60: trcapi32: 001 -GetWindowLongW(,) -> 8911f8
20231125093356719 10468 50.60: trcapi32: 001 +GetCurrentThreadId()
20231125093356720 10468 50.60: trcapi32: 001 -GetCurrentThreadId() -> 29e8
20231125093356720 10468 50.60: trcapi32: 001 +IsWindow(2607f0)
20231125093356720 10468 50.60: trcapi32: 001 -IsWindow() -> 1
20231125093356720 10468 50.60: trcapi32: 001 +GetCurrentThreadId()
20231125093356720 10468 50.60: trcapi32: 001 -GetCurrentThreadId() -> 29e8
20231125093356721 10468 50.60: trcapi32: 001 +GetWindowLongW(2607f0,fffffffe)
20231125093356721 10468 50.60: trcapi32: 001 -GetWindowLongW(,) -> ffffffff
20231125093356721 10468 50.60: trcapi32: 001 -BeginPaint(,) -> 5301041b
20231125093356721 10468 50.60: trcapi32: 001 +IsWindowEnabled(2607f0)
20231125093356721 10468 50.60: trcapi32: 001 -IsWindowEnabled() -> 1
20231125093356721 10468 50.60: trcapi32: 001 +IsWindowEnabled(2607f0)
20231125093356722 10468 50.60: trcapi32: 001 -IsWindowEnabled() -> 1
20231125093356722 10468 50.60: trcapi32: 001 +GetCurrentThreadId()
20231125093356722 10468 50.60: trcapi32: 001 -GetCurrentThreadId() -> 29e8
20231125093356722 10468 50.60: trcapi32: 001 +GetClientRect(2607f0,32f05c)
20231125093356722 10468 50.60: trcapi32: 001 -GetClientRect(,) -> 1
20231125093356723 10468 50.60: trcapi32: 001 +IsRectEmpty(32f05c)
20231125093356723 10468 50.60: trcapi32: 001 -IsRectEmpty() -> 0
20231125093356723 10468 50.60: trcapi32: 001 +GetObjectType(5301041b)
20231125093356723 10468 50.60: trcapi32: 001 -GetObjectType() -> 3

```

Figura 2.1: API Call catturate

Tuttavia, il semplice elenco delle chiamate API non è sufficiente per mostrare la vera natura di un software. È necessario definire una logica in grado di estrarre pattern a partire da questi dati in grado di identificare in maniera automatica i comportamenti malevoli. In questa tesi tali logiche sono implementate tramite *machine learning*.

## 2.2 Machine Learning

Il *machine learning* (ML) è una branca dell'intelligenza artificiale (IA) che consente a computer e macchine di apprendere dai dati, imitando i processi cognitivi umani [22]. In termini pratici, il ML consiste nell'**addestramento** di un software, detto **modello**, per svolgere compiti specifici come effettuare **previsioni** o generare contenuti (testo, immagini, audio o video) a partire da dati osservati [23]. Un modello di *machine learning* può essere visto come un costrutto matematico che riceve dati in ingresso (*input*) e produce un risultato (*output*), in modo analogo a una funzione matematica [24]. L'**allenamento** di un modello consiste nel processo di identificazione dei parametri ottimali interni, così che il modello possa compiere previsioni accurate; ciò avviene fornendogli una serie di

esempi [25]. Un **esempio** è un'istanza di input descritta da un insieme di variabili organizzate in un **vettore delle caratteristiche** (*feature vector*) [26]. Ogni variabile è detta **caratteristica** (*feature*) e rappresenta un'informazione specifica del dominio del problema [27]. Le caratteristiche possono essere di tipo **numerico**, quando esprimono valori quantitativi, oppure **categorico**, quando descrivono attributi qualitativi. Un insieme di esempi costituisce un *dataset*.

I modelli di *machine learning*, in base al tipo di addestramento e ai dati disponibili, possono essere suddivisi in quattro categorie principali:

- **Apprendimento supervisionato**: il modello impara a fare previsioni a partire da dati etichettati, ossia accompagnati dalle risposte corrette, scoprendo le relazioni tra input e output [23].
- **Apprendimento non supervisionato**: il modello lavora con dati privi di etichette e ha come obiettivo l'identificazione di strutture o pattern nascosti nei dati [23].
- **Apprendimento per rinforzo**: il modello interagisce con un ambiente, ricevendo feedback sotto forma di ricompense o penalità, e sviluppa progressivamente una strategia ottimale per il raggiungimento di un obiettivo [23].
- **Apprendimento generativo**: i modelli non si limitano a classificare o predire, ma generano nuovi contenuti (testo, immagini, audio, ecc.) a partire dagli input forniti dall'utente [23].

In questa tesi ci concentreremo sull'**apprendimento supervisionato**, affrontando in particolare il compito di **classificazione**.

## 2.3 Classificazione

Il compito di **classificazione** rientra tra quelli affrontabili tramite *apprendimento supervisionato*. In questo paradigma, gli esempi utilizzati durante l'addestramento sono accompagnati dall'output corretto, detto **etichetta** (label) [28]. Nel caso specifico della classificazione, l'etichetta corrisponde a una **classe**, ossia il valore discreto che identifica a quale categoria appartiene l'esempio. Allenando quindi un modello su un dataset etichettato, l'obiettivo della classificazione è predire la classe corretta di un nuovo esempio non etichettato.

Esistono molteplici compiti di classificazione, distinti uno dall'altro dal numero delle classi da distinguere e da quanto sono mutualmente esclusivi [29].

- **Classificazione binaria**: le classi tra cui predire sono due e mutualmente esclusive [29].



- **Classificazione multi classe:** le classi tra cui predire sono più di due e mutualmente esclusive [29].
- **Classificazione a multipla etichetta:** un esempio può appartenere a più classi [29].

In questo lavoro di tesi verrà affrontata la classificazione multi classe.

### 2.3.1 Algoritmi di Classificazione

Esistono molteplici algoritmi per la classificazione, in questa tesi verranno affrontati *XGboost* e *Random forest*.

#### Random forest

Prima di introdurre l'algoritmo di apprendimento *random forest*, è utile esaminare due concetti fondamentali alla sua comprensione: *bagging* e *decision tree*.

L'algoritmo di apprendimento *bagging* appartiene alla categoria dei metodi di **apprendimento d'insieme**, il cui obiettivo è ridurre la varianza<sup>2</sup> all'interno di un dataset rumoroso [31]. L'apprendimento d'insieme si basa sull'idea che un gruppo di modelli che collaborano possa raggiungere prestazioni superiori rispetto a un singolo modello. Questo principio viene spesso associato al concetto di "saggezza delle folle", secondo cui un insieme di persone fornisce mediamente decisioni migliori di quelle di un singolo esperto [31]. Nel *bagging*, i singoli modelli dell'insieme vengono addestrati — anche in parallelo — su sottoinsiemi del dataset originario, generati tramite campionamento con reinserimento (bootstrap) [30]. Ciò implica che uno stesso esempio possa comparire più volte all'interno di uno o più sottoinsiemi. Al termine dell'addestramento, la previsione finale del sistema viene ottenuta aggregando le risposte di tutti i modelli. Nel caso della classificazione, la classe predetta corrisponde a quella che ha ricevuto il maggior numero di voti.

L'algoritmo *decision tree* è costituito da una serie di domande organizzate gerarchicamente a forma di albero. Le domande sono generalmente chiamate *condizioni*, *split* o *test*. Ogni nodo interno (non foglia) contiene una condizione, mentre ogni nodo foglia rappresenta una previsione. Per effettuare una previsione, si parte dal nodo radice e si percorre l'albero fino a raggiungere un nodo foglia, scegliendo il ramo da seguire in base all'esito della condizione presente in ciascun nodo. Il percorso che va dalla radice fino alla foglia è chiamato *percorso di inferenza* [32].

L'algoritmo *Random Forest* è un'estensione dell'algoritmo di *bagging*, in cui i modelli interni sono costituiti da *decision tree*. Oltre a essere addestrati su sottoinsiemi

---

<sup>2</sup>La varianza si riferisce alla sensibilità del modello rispetto alle fluttuazioni nei dati di addestramento [30].

casuali degli esempi del dataset (*bagging*), ad ogni nodo viene selezionato un sottoinsieme casuale di *feature* candidate per effettuare lo *split*. Questo introduce diversità tra gli alberi, riducendo la correlazione tra di essi e aumentando la robustezza del modello complessivo [33].

## XGBoost

Per una corretta comprensione dell'algoritmo di apprendimento *XGBoost*, è utile introdurre preliminarmente l'algoritmo di apprendimento *boosting* e il concetto di *ascesa del gradiente*.

Il *boosting* è una tecnica di apprendimento sequenziale in cui più modelli vengono addestrati uno dopo l'altro, ciascuno dei quali cerca di correggere gli errori commessi dal modello precedente, al fine di ottenere una previsione progressivamente più accurata [34]. Il *boosting* appartiene alla categoria degli apprendimenti d'insieme.

La *discesa del gradiente* [35] è un algoritmo di ottimizzazione che permette di trovare i valori ottimali dei parametri di un modello minimizzando una funzione di costo. L'idea di base è semplice: si parte da valori iniziali arbitrari per i parametri, si calcola la pendenza (il *gradiente*) della funzione di costo in quel punto e si aggiornano i parametri muovendosi nella direzione opposta al gradiente, cioè verso la discesa più ripida. Il processo si ripete finché non si raggiunge un minimo (locale o globale). Un ruolo cruciale è svolto dal *tasso di apprendimento* (*learning rate*), che stabilisce la grandezza dei passi: se troppo grande vi è il rischio di superare il minimo, mentre se troppo piccolo l'addestramento risulta molto lento. Esistono diverse varianti:

- **Batch Gradient Descent:** aggiorna i parametri dopo aver visto tutti i dati di addestramento [35].
- **Stochastic Gradient Descent (SGD):** aggiorna i parametri dopo ogni esempio, introducendo rumore ma anche la possibilità di sfuggire ai minimi locali [35].
- **Mini-batch Gradient Descent:** compromesso tra i due, suddivide i dati in piccoli blocchi [35].

L'obiettivo della discesa del gradiente è ridurre progressivamente l'errore, fino a convergere a un set di parametri che rende il modello il più accurato possibile.

L'algoritmo di apprendimento *XGBoost* si basa sulla tecnica del *boosting*, in cui un modello iniziale, l'albero decisionale, viene progressivamente migliorato tramite l'uso della *discesa del gradiente* [36].

## 2.4 Approcci di Machine Learning per Windows PE Malware Detection

Diversi studi hanno affrontato il problema della rilevazione dei malware in ambiente Windows basandosi sull'analisi delle chiamate API.

Ad esempio, Zhang et al. (2015) propongono un approccio innovativo per la rilevazione di malware basato sull'analisi dinamica delle sequenze di chiamate API. Gli autori applicano algoritmi di allineamento delle sequenze di DNA per identificare somiglianze tra le sequenze di chiamate API di programmi legittimi e malware. Gli algoritmi di allineamento delle sequenze risolvono il compito di calcolare il costo minimo necessario per trasformare una stringa  $a$  in una stringa  $b$ , consentendo operazioni di *inserimento* (aggiunta di un carattere) e *rimozione* (eliminazione di un carattere). Una delle soluzioni più note a questo problema è l'algoritmo di Smith-Waterman [37]. Nello studio, ogni esempio del dataset è rappresentato da un vettore di feature costituito dai costi di allineamento calcolati tra una sequenza sconosciuta e tutte le sequenze note del dataset. Il modello proposto ha mostrato buone prestazioni nella classificazione dei malware, evidenziando l'efficacia dell'approccio basato sull'allineamento delle sequenze di chiamate API [38].

Amer e Zelinka (2020) introducono un approccio innovativo che combina tecniche di analisi semantica e modellazione probabilistica delle sequenze di API. L'idea si ispira ai metodi utilizzati nell'elaborazione del linguaggio naturale (NLP<sup>3</sup>), trattando le sequenze di chiamate API come frasi e le singole API come parole. Per rendere questa rappresentazione più significativa, gli autori applicano l'algoritmo *Word2Vec* [40], che proietta ogni API in uno spazio vettoriale, in cui elementi che compaiono in contesti simili risultano vicini tra loro. I vettori così ottenuti vengono successivamente organizzati in gruppi omogenei mediante *k-means clustering* [41], un algoritmo non supervisionato che assegna ciascun elemento a un cluster in base alla distanza dal centroide<sup>4</sup>. In questo modo, ogni API originale viene sostituita dall'indice del cluster di appartenenza, riducendo la complessità senza perdere le relazioni semantiche. A partire da questa rappresentazione, gli autori costruiscono due matrici di transizione distinte: una per le sequenze di software benigno e una per quelle malevole. In tali matrici, ciascuna cella rappresenta la probabilità di passare da uno stato  $i$  a uno stato  $j$ . Per classificare una nuova sequenza di API, questa viene mappata nella rappresentazione basata sui cluster e analizzata tramite un modello a catene di Markov, in cui la transizione dipende unicamente dallo stato corrente. Calcolando la probabilità complessiva della sequenza rispetto ai due modelli (goodware e malware), la classificazione viene effettuata scegliendo l'ipotesi con la

---

<sup>3</sup>*Natural Language Processing* è un ramo dell'intelligenza artificiale che abilita i computer a comprendere e interpretare il linguaggio umano [39]

<sup>4</sup>Il centroide è il vettore medio di tutti gli elementi che appartengono a un cluster

probabilità più elevata. I risultati mostrano performance molto promettenti: l'approccio raggiunge un'accuratezza fino al 99% e consente di effettuare previsioni precoci già dalle prime chiamate API, dimostrando l'efficacia della combinazione tra rappresentazione semantica e modellazione probabilistica.

Un contributo più recente è quello di Gond e Mohapatra (2025), che affrontano la classificazione dei malware considerando il fenomeno del *concept drift*, ovvero la capacità dei malware di adattare i propri comportamenti non solo nel tempo, ma anche in funzione del contesto di esecuzione, ad esempio il sistema operativo o l'ambiente (virtualizzato o reale) in cui operano. Gli autori combinano tecniche di deep learning con meccanismi di adattamento al drift: le sequenze di API raccolte tramite sandbox vengono trasformate in rappresentazioni linguistiche tramite n-grammi<sup>5</sup> e filtrate per rilevanza. Successivamente, un algoritmo genetico genera varianti delle feature per simulare nuovi schemi comportamentali emergenti. La classificazione è affidata a reti neurali artificiali, ricorrenti e convoluzionali CNN (Convolutional Neural Networks) [43], raggiungendo accuratze fino al 99,5% anche in presenza di mutazioni nei dati. L'integrazione del genetic algorithm consente di ridurre la perdita di performance dovuta al concept drift [44].

Nello studio "Malware Detection based on API Calls Frequency" [45] La metodologia si articola in diverse fasi: in primo luogo, le chiamate API sono state estratte dai file e trasformate in un vettore di feature. Per ottimizzare il processo di addestramento e rimuovere le funzionalità ridondanti, è stata applicata la tecnica di *feature selection* tramite un algoritmo *Random Forest*. Questo ha permesso di identificare le 45 feature più significative. Successivamente, questi vettori di feature ottimizzati sono stati utilizzati per addestrare vari algoritmi di machine learning. Tra tutti i modelli testati, l'algoritmo *Support Vector Machine* (SVM [46]) ha dimostrato le prestazioni migliori, raggiungendo un'accuratezza del 93% nel distinguere il malware dai file benigni.

Sono stati provati anche approcci a grafo, come nello studio "A malware classification method based on directed API call relationships" [47]. A differenza degli approcci tradizionali che le considerano come una semplice lista, i ricercatori hanno sviluppato un modello che le tratta come un **grafo diretto**. In questo grafo, ogni nodo è una singola API e gli archi direzionali rappresentano l'ordine e la sequenza con cui le chiamate vengono eseguite. La metodologia si concentra sul modello **FSGCN** (First-order and Second-order Graph Convolutional Networks), il quale analizza il grafo su due livelli per estrarre informazioni cruciali. A un livello di *primo ordine*, il modello esamina le connessioni dirette tra le API per comprendere la sequenza immediata. A un livello di *secondo ordine*, analizza le relazioni indirette (percorsi a due passi), per comprendere il contesto più ampio del comportamento del programma. Questa combinazione di analisi consente di

---

<sup>5</sup>Un **n-gramma** è una sotto sequenza contigua di n elementi [42]

creare un **vettore di feature** unificato, che racchiude sia i dettagli della sequenza che il contesto relazionale. Il vettore di feature viene poi convertito in un'immagine, sfruttando l'efficacia delle **CNN** per la classificazione finale. L'efficacia di questo approccio dimostra che l'analisi delle relazioni strutturali e dell'ordine delle chiamate API è un metodo più robusto per la classificazione dei malware.

Questi studi evidenziano come l'analisi delle sequenze di API, se combinata con tecniche di rappresentazione avanzata e modelli adattativi, possa migliorare sensibilmente l'efficacia della malware detection in ambienti Windows.



# Capitolo 3

## Approccio Proposto

In questo capitolo viene illustrato il percorso seguito per la realizzazione del progetto. Nella sezione *Descrizione* vengono presentate le scelte metodologiche e le attività svolte durante lo sviluppo, con l'obiettivo di fornire una panoramica chiara dell'approccio adottato. La sezione *OOP & UML*, invece, entra nel merito dell'implementazione del codice, analizzando l'organizzazione secondo i principi della programmazione orientata agli oggetti e illustrandola mediante diagrammi UML a supporto della progettazione.

### 3.1 Descrizione

La fase sperimentale di questa tesi si è concentrata sulla **classificazione di software** attraverso l'analisi dei pattern comportamentali espressi dalle sequenze di chiamate API. Il percorso metodologico seguito può essere suddiviso nelle seguenti fasi principali: la raccolta e la standardizzazione dei dati, l'ingegneria delle caratteristiche, l'addestramento dei classificatori e la valutazione finale.

#### 3.1.1 Raccolta e Standardizzazione dei Dati

Per l'analisi sono stati raccolti **quattro diversi dataset** da fonti esterne. In origine, questi dati erano disponibili in formati eterogenei (ad esempio CSV<sup>1</sup>, JSON<sup>2</sup>, e formati personalizzati), rendendo difficoltosa un'analisi congiunta e omogenea. Per superare questa limitazione, si è resa necessaria una fase di **standardizzazione** in un unico formato: il **JSON**. La struttura adottata per ogni file standardizzato è stata pensata per

---

<sup>1</sup>Il formato **CSV** (Comma Separated Value) è un formato di condivisione dati in cui ogni riga rappresenta un dato di cui le caratteristiche sono separate da virgola [48].

<sup>2</sup>Il formato **JSON** (JavaScript Object Notation) è un formato per lo scambio di dati basato su una collezione di coppie nome/valore e di array [49].

rappresentare in modo chiaro e minimale le informazioni essenziali per l'addestramento. Il JSON contiene i seguenti campi, come illustrato nell'esempio in Figura 3.1:

Key	Descrizione
<code>[] . application_type</code>	Classe del software ( <i>malware</i> , <i>goodware</i> , ...)
<code>[] . apis</code>	Sequenza di chiamate API (array di stringhe)

```

1  [
2    {
3      "application_type": "malware",
4      "apis": [
5        "getProcessId",
6        "deleteProcess"
7      ]
8    },
9    {
10     "application_type": "goodware",
11     "apis": [
12       "getMessageBox",
13       "openDialog"
14     ]
15   }
16 ]

```

Figura 3.1: Descrizione dei campi e corrispondente esempio JSON.

### 3.1.2 Ingegneria delle Caratteristiche: Il Modello Bag-of-Words

L'obiettivo della classificazione è distinguere le categorie di software basandosi sul loro comportamento, espresso dalle sequenze di chiamate API. Per tradurre queste sequenze in un formato numerico interpretabile dagli algoritmi di Machine Learning, è stato costituito un **vettore delle caratteristiche** (feature vector) basato sulle **frequenze** con cui ogni singola API compare nella sequenza. A tal fine, è stato adottato l'approccio **Bag-of-Words** (BoW). In letteratura, questa tecnica, mutuata dal Natural Language Processing, consente di rappresentare un documento testuale (nel nostro caso, la sequenza di API di un programma) come un vettore numerico che ne riflette il contenuto, **ignorando l'ordine temporale** con cui le “parole” (ovvero, le singole API) compaiono all'interno della sequenza [50]. Per implementare il modello BoW e ottenere il vettore delle caratteristiche, è stata eseguita la seguente procedura:

1. **Creazione del Vocabolario:** Tutte le chiamate API univoche presenti nel dataset sono state estratte per comporre il vocabolario.



2. **Indicizzazione:** Il vocabolario è stato **ordinato alfabeticamente**. Tale ordinamento stabilisce una corrispondenza univoca e fissa: la posizione  $i$ -esima nel vocabolario (data dall'ordine alfabetico) corrisponde alla posizione  $i$ -esima nel vettore delle caratteristiche.
3. **Vettorizzazione:** Per ogni esempio si crea un vettore di interi avente cardinalità pari alla dimensione del vocabolario, con tutti i valori inizialmente pari a zero.
4. **Popolamento:** Per ogni chiamata API presente nella sequenza del esempio, si individua la sua posizione nel vocabolario (grazie all'Indicizzazione) e si **incrementa di 1** il valore nella corrispondente posizione del vettore delle caratteristiche.

Il risultato finale è un vettore di frequenze assolute a lunghezza fissa, in cui ogni componente quantifica il numero di occorrenze di una specifica API.

### 3.1.3 Addestramento e Valutazione

Ottenuti i vettori delle caratteristiche, si è passati alla fase di addestramento. L'implementazione è stata realizzata utilizzando la libreria *Scikit-learn* [51], che offre i modelli *XGBoost* e *RandomForest*. Il processo ha previsto la suddivisione del dataset originario in due istanze:

- **Training Set (80%):** utilizzato per addestrare il modello tramite il metodo *fit*.
- **Evaluation Set (20%):** utilizzato per la valutazione delle prestazioni tramite il metodo *predict*.

Per la divisione è stata applicata la tecnica di **Campionamento Stratificato** (Stratified Sampling) [52]. Tale scelta metodologica è stata essenziale per garantire la **proporzionalità** di presenza di tutte le classi di software in entrambi i sottoinsiemi (training e valutazione). In questo modo si è prevenuta la distorsione del modello, garantendo che anche le classi minoritarie fossero adeguatamente rappresentate nel processo di apprendimento e nella successiva fase di testing.

Infine, nella fase di valutazione, le previsioni effettuate dal metodo *predict* sono state utilizzate per calcolare le metriche di interesse, partendo dalla costruzione della **Matrice di Confusione**.


## 3.2 OOP & UML

La fase di implementazione del progetto è stata condotta adottando il paradigma della **Programmazione Orientata agli Oggetti** (OOP). Questo approccio si è rivelato fondamentale per strutturare il codice in modo *modulare*, *manutenibile* e *scalabile*, in quanto

ha permesso di modellare le entità del problema (come i dataset, le sequenze di API e i classificatori) come componenti software interconnesse. L'efficacia dell'OOP si fonda su quattro pilastri concettuali:

- *Astrazione*: Consente di modellare le entità come classi, focalizzandosi unicamente sugli attributi e sulle interazioni rilevanti per il contesto applicativo, nascondendo la complessità sottostante [53].
- *Incapsulamento*: Protegge lo stato interno di un oggetto, nascondendolo e consentendo l'interazione con le sue funzionalità per garantirne l'integrità [53].
- *Ereditarietà*: Permette di creare nuove astrazioni (sottoclassi) basandosi su astrazioni esistenti (superclassi), facilitando il riuso del codice e stabilendo gerarchie logiche tra le classi [53].
- *Polimorfismo*: Consente a oggetti diversi di rispondere allo stesso messaggio (chiamata di metodo) in modi specifici alla propria classe, permettendo di implementare proprietà o metodi ereditati in forme distinte tra diverse astrazioni [53].

Per formalizzare e documentare questa architettura basata sui principi OOP, è stato utilizzato l'**Unified Modeling Language** (UML) [54]. Nello specifico, il **Diagramma delle Classi** è stato scelto per illustrare la struttura del sistema e le relazioni tra i suoi componenti. Il diagramma delle classi completo che definisce l'architettura logica del progetto è presentato in Figura 3.2.



### 3.2.1 Convenzioni e Notazione UML

Per la corretta interpretazione del Diagramma delle Classi presentato, definiamo le principali convenzioni di notazione UML adottate, relative alla struttura delle classi, alla visibilità e ai tipi di relazioni.

#### Struttura della Classe e Simboli di Visibilità

La classe è l'elemento fondamentale del Diagramma delle Classi. Come mostrato in Figura 3.3, è rappresentata da un rettangolo suddiviso in tre compartimenti che ne definiscono l'identità e il comportamento:

1. **Nome** (Superiore): Contiene il nome della classe.
2. **Attributi** (Centrale): Elenca le proprietà della classe.
3. **Metodi** (Inferiore): Elenca le operazioni della classe.

Il costrutto tra parentesi angolari (**<<nome>>**) viene chiamato *stereotipo* e serve ad estendere il vocabolario del UML, aggiungendo ulteriori significati (es. **<<abstract>>** per indicare un elemento astratto o **<<query>>** per i metodi che non alterano lo stato).




Figura 3.3: UML - Classe

La dichiarazione di un metodo o attributo è preceduta da un simbolo che ne indica la **visibilità**, un concetto fondamentale per definire quali elementi possono interagire con l'oggetto. In Tabella 3.1 sono riepilogati i simboli e il loro significato:

#### Definizione di Attributi e Metodi

La notazione UML stabilisce formati rigorosi per la dichiarazione di attributi e metodi, specificando dettagli come la molteplicità e le proprietà comportamentali. La definizione di un attributo segue il formato:

$$[\langle \text{visibilità} \rangle] \langle \text{nome} \rangle [\langle \text{molteplicità} \rangle] : \langle \text{tipo} \rangle [= \langle \text{valore} \rangle] [\text{proprietà}]$$

Tabella 3.1: Simboli di visibilità in UML

Simbolo	Tipo di visibilità	Descrizione
+	Pubblica	Qualsiasi elemento può accedere
-	Privata	Solo la classe stessa ne ha accesso
#	Protetto	Solo la classe e le sue sottoclassi ne hanno accesso
~	Package	Solo gli elementi dello stesso package ne hanno accesso

*Nota: gli elementi tra parentesi quadre [ ] sono opzionali. La visibilità, se non specificata, va intesa come Protetta.*

La **molteplicità** indica quante istanze<sup>3</sup> sono presenti di quell'attributo; se non espressa si intende 1. Può essere un range nel formato *min..max*, dove *max* può assumere il valore \* per indicare l'assenza di un limite.

I valori assumibili dal campo *proprietà* per gli attributi includono: **changeable** (valore di default), **addOnly** (solo aggiunte in caso di molteplicità > 1), e **frozen** (valore immutabile una volta assegnato).

La definizione di un metodo segue invece questo formato:

$[\langle visibilità \rangle] \langle nome \rangle (\langle lista \text{ parametri} \rangle) : \langle valore \text{ di ritorno} \rangle [\langle proprietà \rangle]$

I valori possibili per le proprietà di un metodo includono **isQuery** (non altera lo stato), **leaf** (non specializzabile), e proprietà relative alla concorrenza come **sequential**, **guarded** e **concurrent**.

## Relazioni Tra Classi

Le classi nel diagramma UML sono collegate da **associazioni** che definiscono le loro interazioni. Tre tipi di relazioni sono fondamentali in questo progetto:

**Composizione (Aggregazione Forte)** La Composizione (Figura 3.4) è una forma forte di associazione che modella la relazione “parte-intero” ed è rappresentata da un **rombo pieno**

attaccato alla classe “intero” (o contenitore). Questa relazione implica che l'esistenza delle “parti” dipende strettamente dall'esistenza dell'oggetto “intero” e che le parti non possono essere condivise. L'esempio mostra come la classe *Sequence* sia composta dalle *ApiCall*, indicando che una sequenza non esiste senza le sue chiamate.

<sup>3</sup>Un **istanza** è una istanziazione di una classe, ovvero un oggetto in esecuzione.




Figura 3.4: UML - Composizione

**Use (Dipendenza Implementativa)** La relazione *use* è formalmente una **\*\*Dipendenza\*\*** (**\*Dependency\***) ed è rappresentata da una linea tratteggiata con freccia. Essa indica una **dipendenza implementativa** a breve termine: la classe Cliente ha bisogno della classe Fornitore per la sua realizzazione funzionale (e.g., come parametro di un metodo) senza conservarne un riferimento strutturale permanente.




Figura 3.5: UML - Use (Dipendenza)

**Extends (Ereditarietà)** La relazione *extends* (Figura 3.6) è fondamentale per l'OOP. Permette alla classe sottoclasse (quella che genera la freccia) di ereditare tutti gli attributi e i metodi della classe padre (quella puntata). Questo facilita il riuso del codice e la specializzazione tramite **\*variazione funzionale\*** dei comportamenti ereditati.

**Implements (Realizzazione)** La relazione *Implements* (Figura 3.7), rappresentata da una linea tratteggiata con freccia triangolare, descrive la **realizzazione di un'interfaccia** (o classe astratta). La classe che genera la freccia si impegna a implementare tutti i metodi astratti definiti nell'interfaccia puntata. Nel nostro diagramma, i classificatori (**RandomForest** e **XGBoost**) realizzano un'interfaccia `<<abstract>> Classifier` che definisce i metodi `fit` e `predict`.

**Package** I **package** in UML (Figura 3.8) sono utilizzati per raggruppare logicamente le classi correlate, migliorando l'organizzazione visiva e concettuale del diagramma delle classi.




Figura 3.6: UML - Extends (Ereditarietà)

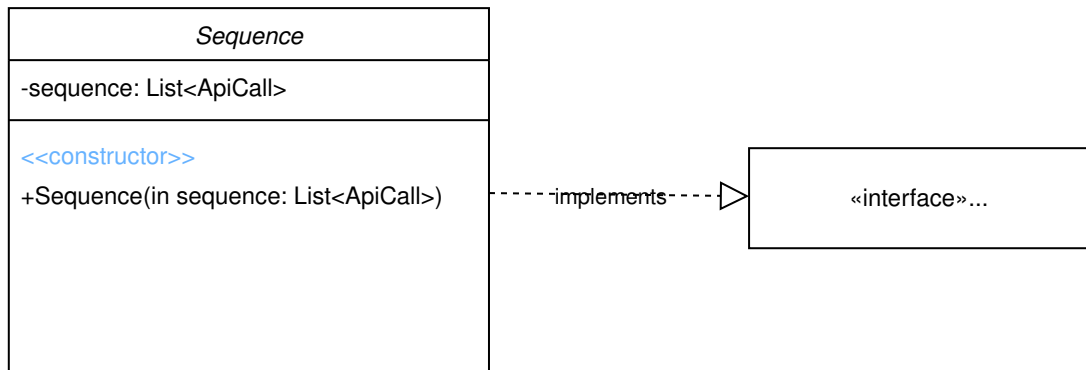


Figura 3.7: UML - Implements (Realizzazione)

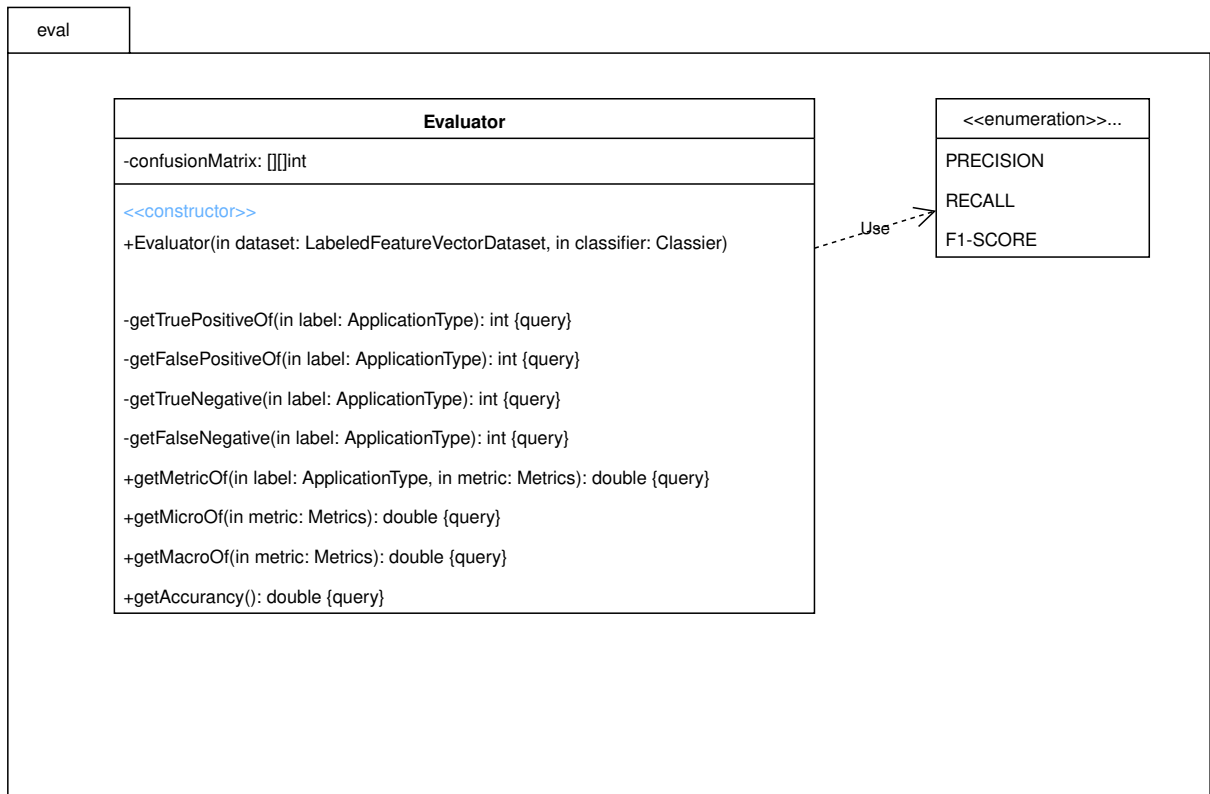


Figura 3.8: UML - Package





# Capitolo 4

## Validazione Empirica

### 4.1 Dataset

### 4.2 Metriche di Valutazione

Per valutare l'efficacia di un classificatore è necessario quantificare quanto esso sia capace di effettuare previsioni corrette su dati diversi da quelli con cui è stato appreso. Uno strumento utile a questo scopo è la **matrice di confusione** [55]. Nella matrice, le righe rappresentano i valori effettivi mentre le colonne indicano quelli predetti; in letteratura è possibile incontrare anche la rappresentazione inversa. La matrice ha tante righe e colonne quante sono le classi presenti nel dataset. L'intersezione tra la riga  $i$  e la colonna  $j$  fornisce il numero di istanze della classe  $i$  che sono state classificate come classe  $j$ . In particolare, gli elementi della diagonale rappresentano le istanze correttamente predette. A partire dalla matrice di confusione è possibile calcolare diverse metriche di valutazione, tra cui la **precision**, la **recall** e l'**F1-score** per ciascuna classe. È inoltre possibile derivare le corrispondenti misure aggregate a livello *macro* e *micro*, utili per valutazioni globali sul dataset. Prima di entrare nel dettaglio delle metriche tornano utili i concetti di **true positive**, **true negative**, **false positive** e **false negative** considerando la matrice di confusione  $M$  avente  $n$  classi.

I **true positive** di una classe  $k$  equivalgono al numero di istanze di classe  $k$  che sono state predette come classe  $k$ :

$$TP_k = M_{k,k}$$

I **false positive** di una classe  $k$  rappresentano il numero di istanze appartenenti a classi diverse da  $k$  che sono state erroneamente predette come  $k$ :

$$FP_k = \sum_{\substack{i=1 \\ i \neq k}}^n M_{i,k}$$

I **false negative** di una classe  $k$  rappresentano il numero di istanze appartenenti a  $k$  che sono state erroneamente classificate come un'altra classe:

$$FN_k = \sum_{\substack{j=1 \\ j \neq k}}^n M_{k,j}$$

I **true negative** di una classe  $k$  rappresentano il numero di istanze appartenenti a classi diverse da  $k$  che sono state correttamente classificate come non  $k$ :

$$TN_k = \sum_{\substack{i=1 \\ i \neq k}}^n \sum_{\substack{j=1 \\ j \neq k}}^n M_{i,j}$$

La **precision** di una classe  $k$  è il rapporto tra i veri positivi e la somma dei veri positivi e dei falsi positivi:

$$\text{Precision}_k = \frac{TP_k}{TP_k + FP_k}$$

La **recall** (o sensibilità) di una classe  $k$  è il rapporto tra i veri positivi e la somma dei veri positivi e dei falsi negativi:

$$\text{Recall}_k = \frac{TP_k}{TP_k + FN_k}$$

L'**F1-score** di una classe  $k$  è la media armonica tra precision e recall:

$$F1_k = 2 \cdot \frac{\text{Precision}_k \cdot \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k}$$

Le metriche **Precision**, **Recall** e **F1-Score** calcolate per ciascuna classe possono essere aggregate per ottenere valori complessivi sul modello intero. Due approcci comuni di aggregazione sono la media *macro* e la media *micro*:

$$\text{Macro}_{\text{precision}} = \frac{\sum_i^n \text{Precision}_i}{n}$$

$$\text{Macro}_{\text{recall}} = \frac{\sum_i^n \text{Recall}_i}{n}$$

$$\text{Macro}_{F1} = \frac{\sum_i^n F1_i}{n}$$

$$\text{Micro}_{\text{precision}} = \frac{\sum_i^n TP_i}{\sum_i^n TP_i + \sum_i^n FP_i}$$

$$\text{Micro}_{\text{recall}} = \frac{\sum_i^n TP_i}{\sum_i^n TP_i + \sum_i^n FN_i}$$

$$TP = \sum_{i=1}^n TP_i,$$

$$FP = \sum_{i=1}^n FP_i,$$

$$FN = \sum_{i=1}^n FN_i,$$

$$\text{Precision} = \frac{TP}{TP + FP},$$

$$\text{Recall} = \frac{TP}{TP + FN},$$

$$\text{Micro-F1} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Una metrica che riassume la prestazione globale è la *overall accuracy*:

$$\text{OverallAccuracy} = \frac{\sum_i^n M_{i,i}}{\sum_{i=1}^n \sum_{j=1}^n M_{i,j}}$$

## 4.3 Risultati



## Capitolo 5

### Conclusioni e Sviluppi Futuri



# Capitolo 6

## Appendice

### 6.1 Ambiente di Sviluppo





# Bibliografia

- [1] L. Zannella, M. Zanella, and M. Rizzo, “Report Cittadini E ICT,” Istat, Report/Study, 2025. [Online]. Available: [https://www.istat.it/wp-content/uploads/2025/04/REPORT\\_CITTADINI-E-ICT\\_2024.pdf](https://www.istat.it/wp-content/uploads/2025/04/REPORT_CITTADINI-E-ICT_2024.pdf)
- [2] C. , “© Clusit - Rapporto 2025 sulla Cybersecurity in Italia e nel mondo,” Clusit, Tech. Rep., Mar. 2025. [Online]. Available: [https://clusit.it/wp-content/uploads/download/Rapporto\\_Clusit\\_03-2025\\_web.pdf](https://clusit.it/wp-content/uploads/download/Rapporto_Clusit_03-2025_web.pdf)
- [3] N. Idika and A. P. Mathur, “A survey of malware detection techniques,” *Purdue University*, vol. 48, no. 2, pp. 32–46, 2007. [Online]. Available: [https://profsandhu.com/cs5323\\_s17/im\\_2007.pdf](https://profsandhu.com/cs5323_s17/im_2007.pdf)
- [4] Y. Ki, E. Kim, and H. K. Kim, “A novel approach to detect malware based on api call sequence analysis,” *International Journal of Distributed Sensor Networks*, vol. 11, no. 6, p. 659101, 2015. [Online]. Available: <https://doi.org/10.1155/2015/659101>
- [5] Microsoft, “Introduction to APIs.” [Online]. Available: <https://learn.microsoft.com/en-us/xandr/industry-reference/intro-to-apis>
- [6] Y. Qiao, Y. Yang, L. Ji, and J. He, “Analyzing malware by abstracting the frequent itemsets in api call sequences,” in *2013 12th IEEE International Conference on Trust, Security and Privacy in Computing and Communications*, July 2013, pp. 265–270. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/6680850>
- [7] Microsoft, “Formato pe - win32 apps.” [Online]. Available: <https://learn.microsoft.com/it-it/windows/win32/debug/pe-format>
- [8] —, “Libreria di collegamento dinamico.” [Online]. Available: <https://learn.microsoft.com/it-it/troubleshoot/windows-client/setup-upgrade-and-drivers/dynamic-link-library>
- [9] Kaspersky, “Trojan droppers.” [Online]. Available: <https://encyclopedia.kaspersky.com/glossary/backdoor/>
- [10] Cisco, “What is a malware.” [Online]. Available: <https://www.cisco.com/site/us/en/learn/topics/security/what-is-malware.html>
- [11] Kaspersky, “Trojan droppers.” [Online]. Available: <https://encyclopedia.kaspersky.com/glossary/trojan-droppers/>

- [12] —, “Multipacked.” [Online]. Available: <https://encyclopedia.kaspersky.com/knowledge/multipacked/>
- [13] Microsoft, “Indice di api windows - win32 apps.” [Online]. Available: <https://learn.microsoft.com/it-it/windows/win32/apiindex/windows-api-list>
- [14] —, “Getkeyboardstate - win32 apps.” [Online]. Available: <https://learn.microsoft.com/it-it/windows/win32/api/winuser/nf-winuser-getkeyboardstate>
- [15] D. Heath, S. Kasif, and S. Salzberg, “k-dt: A multi-tree learning method,” in *Proceedings of the Second International Workshop on Multistrategy Learning*, 1993, pp. 138–149.
- [16] T. Chen. (2016) Xgboost: A scalable tree boosting system. Archived on 2016-08-07. [Online]. Available: <https://web.archive.org/web/20160817055008/http://arxiv.org/abs/1603.02754>
- [17] M. Christodorescu and S. Jha, *Static Analysis of Executables to Detect Malicious Patterns* \*. USENIX Association, 2003. [Online]. Available: [https://pages.cs.wisc.edu/~jha/jha-papers/security/usenix\\_2003.pdf](https://pages.cs.wisc.edu/~jha/jha-papers/security/usenix_2003.pdf)
- [18] S. Cesare and Y. Xiang, *Software similarity and classification*, 2012th ed. Guildford, England: Springer, 2012.
- [19] “Detours: Detours is a software package for monitoring and instrumenting API calls on windows. it is distributed in source code form.” [Online]. Available: <https://github.com/microsoft/Detours>
- [20] DynamoRIO Project, “Dynamorio: Dynamic binary instrumentation tool,” <https://dynamorio.org/>, 2025, accessed: 2025-09-20.
- [21] wtrance.net, “Using withdll and detours to trace win api calls,” <https://wtrance.net/guides/using-withdll-and-detours-to-trace-winapi/>, Nov. 2023, accessed: 2025-09-20.
- [22] IBM, “Che cos’è il machine learning (ml)?” Mar. 2025, accessed: 2025-09-21. [Online]. Available: <https://www.ibm.com/it-it/think/topics/machine-learning>
- [23] Google, “Che cos’è il machine learning?” accessed: 2025-09-21. [Online]. Available: <https://developers.google.com/machine-learning/intro-to-ml/what-is-ml?hl=it>
- [24] —, “Glossario del machine learning,” accessed: 2025-09-21. [Online]. Available: <https://developers.google.com/machine-learning/glossary?hl=it#model>
- [25] —, “Glossario del machine learning,” accessed: 2025-09-21. [Online]. Available: <https://developers.google.com/machine-learning/glossary?hl=it#training>
- [26] —, “Glossario del machine learning,” accessed: 2025-09-21. [Online]. Available: <https://developers.google.com/machine-learning/glossary?hl=it#example>
- [27] —, “Glossario del machine learning,” accessed: 2025-09-21. [Online]. Available: <https://developers.google.com/machine-learning/glossary?hl=it#feature>

- [28] —, “Glossario del machine learning,” accessed: 2025-09-21. [Online]. Available: <https://developers.google.com/machine-learning/glossary?hl=it#class>
- [29] I. Belcic, “What is classification in machine learning?” Sep. 2025. [Online]. Available: <https://www.ibm.com/think/topics/classification-machine-learning>
- [30] T. Mucci, “Cosa sono l’overfitting e l’underfitting?” Mar. 2025. [Online]. Available: <https://www.ibm.com/it-it/think/topics/overfitting-vs-underfitting>
- [31] “Cos’è il bagging?” Jun. 2025. [Online]. Available: <https://www.ibm.com/it-it/think/topics/bagging>
- [32] “Alberi decisionali (decision trees).” [Online]. Available: <https://developers.google.com/machine-learning/decision-forests/decision-trees?hl=it>
- [33] “Che cos’è la foresta casuale,” Feb. 2025. [Online]. Available: <https://www.ibm.com/it-it/think/topics/random-forest>
- [34] “Che cos’è il boosting,” Nov. 2024. [Online]. Available: <https://www.ibm.com/it-it/topics/boosting>
- [35] “Che cos’è la discesa del gradiente?” Jan. 2025. [Online]. Available: <https://www.ibm.com/it-it/think/topics/gradient-descent>
- [36] E. Kavlakoglu and E. Russi, “Che cos’è xgboost?” Jan. 2025. [Online]. Available: <https://www.ibm.com/it-it/think/topics/xgboost>
- [37] T. F. Smith, M. S. Waterman *et al.*, “Identification of common molecular subsequences,” *Journal of molecular biology*, vol. 147, no. 1, pp. 195–197, 1981.
- [38] Y. Ki, E. Kim, and H. K. Kim, “A novel approach to detect malware based on api call sequence analysis,” *International Journal of Distributed Sensor Networks*, vol. 11, no. 6, p. 659101, 2015. [Online]. Available: <https://doi.org/10.1155/2015/659101>
- [39] C. Stryker and J. Holdsworth. (2025) Cos’è l’nlp (elaborazione del linguaggio naturale)? Data di consultazione: 25 settembre 2025. [Online]. Available: <https://www.ibm.com/it-it/think/topics/natural-language-processing>
- [40] W. contributors, “Word2vec,” data di consultazione: 25 settembre 2025. [Online]. Available: <https://it.wikipedia.org/w/index.php?title=Word2vec&oldid=145522864>
- [41] E. Kavlakoglu and V. Winland. (2025, feb) Cos’è il k-means clustering? Data di consultazione: 25 settembre 2025. [Online]. Available: <https://www.ibm.com/it-it/think/topics/k-means-clustering>
- [42] Wikipedia contributors, “N-gramma,” <https://it.wikipedia.org/w/index.php?title=N-gramma&oldid=140364382>, 2024, wikipedia, The Free Encyclopedia.
- [43] IBM, “What are convolutional neural networks?” <https://www.ibm.com/think/topics/convolutional-neural-networks>, Sep. 2025, iBM.com.
- [44] B. P. Gond and D. Mohapatra, “Deep learning-driven malware classification with api call sequence analysis and concept drift handling,” *arXiv*, vol. abs/2502.08679, 2025. [Online]. Available: <https://arxiv.org/abs/2502.08679>

- [45] V. Garg and R. K. Yadav, “Malware detection based on api calls frequency,” in *2019 4th International Conference on Information Systems and Computer Networks (ISCON)*, 2019, pp. 400–404. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/9036219/authors#authors>
- [46] IBM, “What is support vector machine?” June 2025. [Online]. Available: <https://www.ibm.com/think/topics/support-vector-machine>
- [47] C. Ma, Z. Li, H. Long, A. Bilal, and X. Liu, “A malware classification method based on directed api call relationships,” *PLOS ONE*, vol. 20, no. 3, pp. 1–26, 03 2025. [Online]. Available: <https://doi.org/10.1371/journal.pone.0299706>
- [48] Y. Shafranovich, “Common format and mime type for comma-separated values (csv) files,” Internet Engineering Task Force (IETF), RFC 4180, 2005. [Online]. Available: <https://www.rfc-editor.org/rfc/rfc4180>
- [49] T. Bray, *The JavaScript Object Notation (JSON) Data Interchange Format*, T. Bray, Ed. RFC Editor, 2017.
- [50] Wikipedia contributors, “Bag-of-words model,” [https://en.wikipedia.org/w/index.php?title=Bag-of-words\\_model&oldid=1289978794](https://en.wikipedia.org/w/index.php?title=Bag-of-words_model&oldid=1289978794), May 2025, accessed: 2025-09-26.
- [51] Scikit-learn developers, “Scikit-learn: Machine learning in python,” <https://scikit-learn.org/stable/index.html>, 2025, accessed: 2025-09-26.
- [52] Wikipedia contributors, “Campionamento stratificato,” 2025, ultimo accesso: 26 settembre 2025. [Online]. Available: [https://it.wikipedia.org/w/index.php?title=Campionamento\\_stratificato&oldid=141667417](https://it.wikipedia.org/w/index.php?title=Campionamento_stratificato&oldid=141667417)
- [53] B. Wagner, “Programmazione object-oriented in c#,” 2023, accessed: 2025-09-26. [Online]. Available: <https://learn.microsoft.com/it-it/dotnet/csharp/fundamentals/tutorials/oop>
- [54] IBM Developer, “The class diagram,” 2023, accessed: 2025-09-27. [Online]. Available: <https://developer.ibm.com/articles/the-class-diagram/>
- [55] J. Murel and E. Kavlakoglu, “Che cos’è una matrice di confusione?” Feb. 2025. [Online]. Available: <https://www.ibm.com/it-it/think/topics/confusion-matrix>